

何鑫奎 大模型应用开发 | Agent Engineer

手机: 18211306275 | 邮箱: hexinkui_hitsz@163.com



教育经历

哈尔滨工业大学 (深圳)	通信工程 本科	2020.09 – 2024.06
哈尔滨工业大学 (深圳)	通信工程 硕士	2024.09 – 至今

- 脑影像机器学习共一作论文 (在投)**: 为刻画自闭症患者个体差异下的脑结构异常, 基于 2965 例人脑核磁共振影像开展个体化结构偏差研究 (独立负责医学影像预处理、特征提取、特征工程与机器学习建模, 完成实验设计与论文撰写)。
- 图神经网络疾病分类实验**: 基于脑结构网络构建图数据, 采用 PyTorch 实现 GCN/GAT 等模型进行自闭症患者与健康对照分类, 评估图拓扑特征对分类性能的影响; 负责特征构建、模型训练与实验对比。

项目经历

智能数据查询分析系统 项目链接: [Github](#) 角色: 全栈开发 2025 年 11 月 - 2026 年 02 月

- 项目介绍**: 面向电商数据分析场景设计的自然语言问数智能体系统, 用户通过中文提问即可自动完成元数据检索、SQL 生成、校验执行与结果展示, 解决业务人员无法直接查数仓的痛点。
- 技术栈**: LangGraph、LangChain、MySQL、Qdrant、Elasticsearch、FastAPI、SSE、React、Redis
- 核心技术实现**:
 - 元数据知识库构建**: 通用 LLM 直接生成 SQL 易因缺乏表结构信息导致幻觉。设计 MySQL+Qdrant+Elasticsearch 三层知识底座, 融合结构化元数据、语义向量和字段检索能力, 支撑 5 张核心业务表、24 个字段及 2 类业务指标的语义映射, 为 SQL 生成提供精准上下文。
 - 多路召回与 LangGraph 工作流编排**: 基于 LangGraph 编排"关键词抽取 → 多路召回 → 合并召回信息 → 过滤补全上下文 → SQL 生成 → 校验 → 纠错 → 执行"的完整流水线。关键词抽取与多路并行召回将用户自然语言问题精准映射到表字段与指标, 解决大模型盲写 SQL 带来的表名/字段名误用问题, 多轮测试中 SQL 执行成功率达 90% 以上。
 - 工程化实现与实时交互**: 基于 FastAPI 异步架构+SSE 流式推送, 实现 LangGraph 各阶段状态实时回传前端, 支持用户观察完整执行链路。基于 LLM 查询补全机制支持多轮对话, 会话状态通过 Redis 持久化; 前端采用 React+Vite+Tailwind CSS, 并结合 SQLAlchemy ORM、Loguru 完成系统配置管理、日志追踪与生命周期管控。

Multi-Agent 智能研究助手 项目链接: [Github](#) 角色: 全栈开发 2026 年 03 月 - 2026 年 06 月

- 项目介绍**: 面向复杂调研场景设计的 Multi-Agent 系统, 用户输入任务或上传文件后, 自动完成任务拆解、信息检索、结果聚合与报告生成, 支持网络搜索、数据库、知识库及本地文件多源协同。
- 技术栈**: LangGraph、LangChain、DeepAgent、Tavily、MySQL、RAGFlow、FastAPI、WebSocket、React
- 核心技术实现**:
 - 层级式多智能体架构**: 采用"主 Agent 统筹 + 专家子 Agent"的分层架构, 由主 Agent 负责任务理解与调度, 网络搜索、数据库查询、知识库检索 (RAGFlow) 三个子 Agent 分别负责对应领域信息获取。通过 Tool 隔离和上下文裁剪降低单 Agent 复杂度, 基于 LangGraph checkpointer (SQLite 持久化) 实现多轮会话记忆, 服务重启后上下文不丢失。
 - 长任务实时推送与稳定性处理**: 基于 FastAPI + ContextVar 构建异步任务调度框架, 实现请求级上下文隔离。支持 1000+任务并发提交和异步调度, thread_id 独立管理会话状态与输出目录, 避免并发串扰; 基于 WebSocket 实现 Agent 执行过程实时推送, 并加入心跳保活、自动重连及资源清理机制。
 - 上下文工程与评测体系**: 自建 token 用量计量与成本核算, 裁剪无用工具 schema 使静态底座降低 32%, 利用上下文缓存使多轮命中率提升至 80%; 构建 5 层 Agent 评测体系 (链路/工具/任务成功/质量/效率), 基于 WebSocket 轨迹采集与 LLM Judge 量化评分, 驱动迭代优化。

专业技能

- 大模型/Agent 开发**: 具备大模型应用与 Agent 系统开发实践经验, 熟悉 LangGraph 多智能体编排、RAG 检索增强、Tool Calling 及 LLM 应用工程。具备本地大模型部署及 LoRA 参数微调实践经验, 熟练掌握 Linux 开发环境及 Docker 部署。
- 模型与算法基础**: 掌握 Transformer 架构原理及大模型训练/推理流程, 具备机器学习、深度学习算法复现能力, 熟悉 PyTorch 模型开发与训练, 掌握图神经网络 (GCN/GAT) 建模, 可处理知识图谱等图结构数据, 能够开展论文复现、实验验证与算法分析。