

余林杨

yulingyu08@gmail.com | github.com/Neon549

求职意向: Agent应用开发 | 电话: 17784322153



教育背景

新南威尔士大学 - 人工智能 · 硕士	2025.03 - 2027.04
· 专业排名: 硕士阶段 23/600	
重庆科技大学 - 计算机科学与技术 · 本科	2020.09 - 2024.06
· 专业排名: 本科阶段 3/140	
· 荣誉: 全国工程大赛后端组国三等奖、蓝桥杯软件赛道省二等奖、两次校级一等奖学金、IELTS 7.0	

项目经历

AlphaStock - 金融长距离量化 Agent GitHub 120+ Stars	https://github.com/Neon549/Alpha_stock
--	---

面向 A 股投研场景, 将受限 Agent 编排、金融 RAG、证据回链、拒答和 Human-in-the-loop 审核纳入同一运行闭环。

Agent 运行时与治理

- 运行编排: 搭建 Gateway - InvestmentRuntime - Python State Machine 链路; ResearchHarness 仅允许白名单只读工具, 单任务最多 3 次调用、单结果最多 1800 字符; Skill Registry 约束 Subagent 权限, 最终输出默认进入人工审核。
- 检索与证据: 针对 1,408 条新闻快照补充 84 个官方公告证据块, 覆盖评测股票; 通过 source_url 去重与金融意图分槽, 关键词覆盖诊断从 0.6191 提升至 0.6530。

上下文工程与评测

- 上下文与记忆: 以 6000 Token 预算组装 Bootstrap、Skill、偏好、Session Memory、近期对话和当前请求; 70% 起按优先级裁剪, 85% 设为硬上限, 候选记忆经人工审核后写入 approved Markdown, 再通过 pgvector HNSW 检索。
- 评测与策略: 在内部公开新闻对照集上进行 RAGAS 消融; 加入官方公告与意图分槽后, Faithfulness 从 0.8533 提升至 0.9660, 据此将 news-first 设为默认, 公告仅在候选不足时补位。

技术栈: AgentRuntime · Harness · Subagent · Skill Registry · PostgreSQL · pgvector · MinerU · MCP · React

TechLens (基于 Qwen3-1.7B) - 本地金融分析模型	https://github.com/Neon549/TechLens-1.5B
-------------------------------------	---

面向投研系统技术分析模块, 训练本地小模型降低云端 API 延迟和成本, 并约束结构化指标输出与错误分析。

训练与服务集成

- 数据与评测: 基于随机游走模拟 A 股日 K 线, 按 KDJ/MA20 规则生成 Ground Truth; 构建 2000 条七类训练样本和物理隔离的 210 条评测集, 覆盖正常行情、工具错误和数据不足。
- SFT/DPO 与规则: 使用 Qwen3-1.7B + LoRA 训练 3 epoch, 构造 400 对 chosen/rejected 偏好数据; 以代码断言评测 6 维指标, 离线评测中价位编造率由 10% 降至 0%。
- 部署与服务: 以 BF16 GPU 部署 LoRA 权重并接入 Agent 在线调用, 支持工具缺失自动补数、异常安全中止和云端降级; 真实请求集 P50 5.82 秒、服务成功率 97.6%。

技术栈: Qwen3-1.7B · LLaMA-Factory · LoRA · DPO · bitsandbytes · DeepSpeed

开源经历

ByteDance DeerFlow - 开源贡献者 80k+ GitHub Stars	github.com/bytedance/deer-flow
--	---

- # 4885 Memory 工程贡献: 针对 DeerMem 长期记忆事实管理提出 [Issue #4880](#), 并提交 [PR #4885](#); 扩展 MemoryManager ABC 与 DeerMem backend 的批量删除、批量分类更新能力, 新增批量 API、React Query 乐观更新、全选与批量操作 UI。
- # 4895 工程化与验证: 补充请求/响应模型、前后端类型、确认弹窗及单元、API 与集成测试, 覆盖批量事实操作的状态同步与边界行为。

技术能力

- Agent 编排: AgenticLoop、Python State Machine、Planner、Harness、Tool Calling、Skills、Subagent、模型路由与降级
- 上下文与证据治理: 熟悉 Context/Memory 管理、上下文压缩、优先级裁剪、记忆分层; RAG、BM25/Dense/RRF、LLM/Agent 评测
- 模型训练与工程化: LoRA/QLoRA、DPO、INT8/BF16、Python、FastAPI、React、PostgreSQL、Docker、Linux、Git、MCP
- AI 工具与架构理念: 熟悉并使用 Codex、Claude Code、DeepSeek Harness; 研读并分析 Hermes、OpenClaw、DeerFlow 等开源范式