



吴培俊

✉ 19859022015@163.com ☎ 19859022015

Education

香港中文大学	硕士
计算机科学与技术(信息工程)	2026.9-2027.11
东南大学	本科
计算机科学与技术	2022.9-2026.6
GPA:3.2/4.0	
核心课程:程序设计基础及语言、数据结构、计算机组成原理、编译原理、计算机网络、操作系统	

Projects

Rethinking LLM Ensembling from the Perspective of Mixture Models	第二作者
ICML2026 Spotlight	

- 设计并实现一种高效 LLM 集成方法，将传统需要多模型同时推理的 ensemble 优化为**单模型逐步调用机制**，显著降低推理计算开销并大幅提升推理效率
- 设计并实现 **KV Cache 同步机制 (Lazy KV Cache)**，通过按需补齐历史上下文，有效解决多模型切换带来的缓存不一致与重复计算问题
- 在多个数据集上开展系统实验，验证方法在不同场景下的稳定性与泛化能力，推理速度提升 **1.8x-2.6x**，性能基本保持一致
- 支持异构模型集成（不同结构与词表），兼容多种主流 LLM 架构，提升方法在实际推理部署与多模型协同场景中的适用性

智能AI Agent系统

基于Spring AI框架构建的智能AI Agent系统 实现了自主决策、工具调用和知识库检索功能
系统采用Think-Execute循环机制，支持多模型切换、RAG检索、能够完成复杂的多步骤任务

技术栈：Spring AI, PostgreSQL, React, SSE

项目成果：

- 实现了完整的AI Agent系统，实现工具调用系统，支持固定工具和可选工具的灵活配置
- 设计多模型支持机构，实现多种大语言模型接入
- 基于RAG技术实现知识库检索功能，使用pgvector进行向量相似度搜索

分布式RPC通信框架

基于 Java、Netty、Zookeeper 实现的 RPC 框架，支持服务注册与发现、动态代理调用、自定义通信协议、多种序列化方式、负载均衡、失败重试、限流、熔断、心跳检测。

技术栈：Java、Netty、Zookeeper

主要工作：

- 基于 Netty 实现客户端与服务端通信，设计自定义编解码器，完成消息类型、序列化方式、消息长度和消息体的协议封装
- 基于 Zookeeper 和 Curator 实现服务注册与发现；在客户端建立缓存，避免频繁访问注册中心
- 为客户端提供多种负载均衡策略选择并实现熔断器机制，监测服务调用情况进行3种状态的切换，从而实现熔断保护
- 基于 Guava Retry 实现对白名单上幂等性服务进行超时重试机制，指定重试策略

Skills

编程语言：C++, Python, Java

语言能力：英语 CET4,CET6,IELTS(6.5)