

吴鹏举

男 | 汉族 | 2002.11.27 | 17629744327 | 可实习时长: 1年 | 邮箱: 374325051@qq.com



教育背景

四川农业大学 (211、双一流) 计算机技术 (硕士) 2025.09-2028.06

河南工业大学 数据科学与大数据技术 (本科) 2020.09-2024.06

- 主修: 智能算法设计97、数据库94、操作系统91、线性代数91、数字图像处理88、数据结构85
- 国家励志奖学金 (2022)、优秀学生干部 (2021)、优秀共青团员 (2022、2023)

项目经历

</> Mini-Coding Agent: 轻量级 AI 编程 Agent 框架

技术栈: React Agent Context Engineering Memory Management Python JSON Schema Shell Sandbox

项目描述: 基于 ReAct 范式实现面向代码任务的轻量级 Agent Runtime, 解决 LLM 在工程任务中的上下文膨胀、工具调用不稳定、长任务中断难恢复等问题, 支持多工具编排、上下文压缩、权限控制与跨会话记忆。

- 核心架构: 设计 QueryEngine+Query() 双层执行架构, 解耦会话生命周期与单次任务执行循环, 实现 LLM 推理、工具调用、结果反馈的多轮迭代; 引入 SQLite Checkpoint 快照机制, 支持任务中断后基于 session_id 恢复。
- 工具系统: 实现基于 JSON Schema 插件式工具注册机制, 新工具继承 Tool 基类接入; 内置文件读写、代码搜索、Git、Shell、Skill 与子 Agent 工具, 支持只读工具并发执行、写入工具串行调度、异常捕获和结构化结果注入。
- 上下文与记忆: 基于 Tiktoken 监控 Token 使用, 设计工具结果裁剪、历史清理、上下文折叠与 autocompact 渐进式压缩策略; 实现 Session Memory 与 Long-term Memory 两级记忆, 持久化用户偏好、项目决策和外部引用。

基于 RAG 的 AI 团队知识库智能问答助手

技术栈: Python LangChain LangGraph RAG MilvusDB RAGAS

项目描述: 设计并实现一个完整的 RAG 知识库系统, 覆盖数据处理、向量索引、检索优化、智能生成、效果评估全链路, 支持多格式数据接入和多种检索策略的灵活切换。灵活解决了 AI 团队内部积累的大量异构资料, 传统的关键词搜索无法理解语义, 员工查找信息效率低, 且大语言模型存在知识过时和幻觉问题。

- 索引层: 集成 BGE-large-zh-v1.5 稠密嵌入模型 (1024 维), 同时支持 Milvus 分布式向量数据库和本地 FAISS 两种存储后端, 引擎启动时自动检测 Milvus 可用性并降级; 实现了 HNSW 索引参数调优和批量插入优化。
- 检索层: 采用策略模式实现多种可插拔检索优化策略——混合检索、查询重构、结果过滤及 ColBERT 重排序、C-RAG 校正等; 设计查询路由器, 通过规则匹配+LLM 意图分析自动选择最优策略, 主策略无结果时自动降级。
- 评估层: 封装 RAGAS 框架的 4 个核心指标 (忠实度/相关性/精确率/召回率), 运用 LLM-As-Judge 的思想自定义 Hit Rate@K、MRR、延迟 P50/P95/P99 等业务指标, 支持多策略批量对比评估并生成可视化报告。

个人技能

- 计算机基础: 扎实掌握操作系统及数据结构与算法, 为构建高并发、高性能系统提供底层支撑。
- 编程&工具: Python、C#、Linux、Docker、tmux、MilvusDB、Claude Code、Codex 等。
- Agent: 熟悉 LangGraph/MCP 协议与 ReAct/Plan-Execute/Muti-Agent 等编排范式。
- RAG: 熟悉搭建流程以及 Milvus 向量数据库、掌握检索优化策略以及 RAG 的评估工程。