

张尘朴

19129514006 | 1662968917@qq.com | 广东-深圳

教育背景

吉林大学 - 985 211 双一流 - 本科

2023-09 ~ 2027-06

技能特长

具有扎实计算机基础，熟练掌握**数据结构与算法、计算机网络、操作系统、面向对象编程**等，熟悉**C/C++、编译原理、计算机组成原理**，熟悉**各种网络协议以及其底层原理**，了解软件工程，有Linux系统下开发的经验，熟悉Docker的使用
熟练掌握Claude Code, Codex等AI编程工具的使用，有完整的项目级开发经验，具有较好的**Prompt编写与调优能力**
熟悉AI大模型相关知识，熟悉**MCP、Skill、A2A协议、Transformer架构、RAG调优、KVCahce优化**等技术，熟悉**向量检索原理、向量库底层索引原理与选型**，阅读过Claude Code源码，并将设计理念运用到个人Agent项目中，了解SDD架构
熟悉分布式下常见理论，熟悉**Paxos算法、Raft算法、分布式事务、分布式ID使用及其原理**等
熟悉Java基础知识，熟悉**JVM、JUC**，熟悉**Java中各种锁机制、CAS、AQS、线程池、垃圾回收、类加载机制、双亲委派机制**等
熟悉**MySQL数据库以及常见优化手段**，有**慢SQL排查优化经历**，深刻理解**Redis架构、IO模型、分布式锁的实现原理**等
熟悉SSM、SpringBoot、SpringCloud、LangChain4j等框架，了解**IOC、AOP、Bean的生命周期**等

实习经验

吉林松辽水资源开发有限责任公司

2026-04~至今

- 参与水资源领域RAG问答链路设计，将请求处理拆分为意图路由、查询改写、知识检索、结果重排、Prompt组装及答案生成等节点；通过条件分支区分问候、越界问题、简单问答与复杂分析，避免无效检索及模型调用。
- 基于CompletableFuture与受控线程池实现Dense向量检索和BM25关键词检索并行执行，经RRF融合及重排后生成候选证据；记录各节点耗时、召回片段和相关度评分，Recall@5由**74%**提升至**88%**、nDCG@5由0.74提升至0.84，引用准确率达到92%；在20并发下检索P95控制在1.209s、首Token耗时控制在1.8s以内。
- 面向跨地区、跨主题的复杂水资源问题，设计**串并行结合**的任务编排机制：**串行链**执行问题拆解、证据聚合及答案生成，并将相互独立的检索与分析任务**并发提交**至内部多实例模型服务；通过并发上限、节点超时和部分结果降级保障链路稳定性。
- 基于Redis维护会话摘要、最新消息及省份、流域、年份等业务槽位，通过滑动窗口限制Prompt长度并支持多轮指代补全；基于**SSE**实现答案流式输出，并将生成任务与客户端连接解耦；通过**MySQL定时快照**与序列号防乱序覆盖，实现**断线后台续写、重连恢复**及异常回答留存。
- 抽象ChatModel、Embedding及Rerank统一服务接口，支持开发环境干问服务与单位内部模型服务切换；为外部模型调用增加超时、重试、限流和异常降级机制，在模型不可用时保留检索证据并返回可解释结果。

项目经验

知映——视频分享社区

个人独立开发

<https://zhimian.tech>

技术栈: SpringBoot、LangChain4j、Vue3、Vite、RocketMQ、Redis、MySQL、Milvus、Spring Security、Caffeine、Sentinel、Fluent bit、Loki、Multi-Agent、Docker、Nginx

项目介绍: 基于Spring Boot 3 + 多模态 AI + RAG 技术构建的高并发视频分享社区，支持视频上传转码、多模态内容审核、视频点赞评论、用户关注等功能，基于异步事件驱动架构支撑高并发交互场景，为用户提供端到端的视频创作与消费体验。

个人职责:

- 基于**Spring Security + OAuth 2.0**实现微信登录认证体系。JWT 采用 RS256 非对称签名，私钥签发公钥验证，支持微服务独立验签。OAuth 2.0 授权流程采用 SecureRandom 生成 state 参数存 Redis 进行一次性校验，防御 CSRF 攻击与重放攻击。双 Token 机制实现无感会话管理，Refresh Token 配合 Rotation + SHA-256 哈希重用检测，被盗用时自动熔断全部会话。Redis Token 黑名单实现服务端即时注销，微信回调采用一次性授权码交换 Token，杜绝 URL 泄漏
- 基于阿里云OSS实现**视频文件分片+断点续传**机制，前端通过预签名URL直传OSS，基于OSS记录上传状态 + 动态分片大小自适应，解决不良网络环境下的传输超时问题。基于MD5实现**内容级去重**，使用**Redisson分布式锁+看门狗机制**防重复合并，防止并发写入导致文件损坏，并基于Apache Tika进行文件内容Magic Number校验防止扩展名伪造，定时任务每小时扫描清理过期会话和 OSS 碎片，合并失败时自动调用 abort 清理，彻底解决存储泄漏问题
- 基于Plan-Execute + Multi-Agent架构实现了**多模态视频内容审核Agent**，PlannerAgent根据视频时长动态制定抽帧策略，VisualAgent、AudioAgent、MetadataAgent 三路并行审核，JudgeAgent进行综合裁决，两层模型通过阿里云内容安全 API 初筛过滤 80% 安全内容，仅对疑似违规帧触发 Qwen-VL 深度分析，配合首尾高密度 + 均匀采样 + 疑似区间加密复检的抽帧策略，单视频审核成本控制在 ¥0.1 以内，解决人工审核成本高、单一模型覆盖率不足的问题。
- 基于**Redis分片位图+RocketMQ 攒批+Caffeine三级缓存**实现点赞功能，点赞事件写入内存队列攒批后发 MQ，针对超高频用户在攒批层做去重压缩，消费者端通过 Lua 脚本批量原子操作 Redis 分片位图完成去重判重，最终批量落库 MySQL 位图快照；内置多级降级策略+ 三级定时对账+**Mmap本地日志容灾**，保证数据最终一致且中间件故障时功能不中断
- 实现了基于滑动窗口计数的**热点Key自动探测**与本地缓存系统。通过@HotKey注解+AOP拦截的方式，在500ms内自动识别高并发访问的热点视频/用户Key，将热Key读取全部路由到Caffeine本地缓存，解决了热点内容的高并发读请求打垮Redis的问题
- 基于LangChain4j + qwen大模型构建**运维告警自动分析 Agent**，感知层自动接收 Grafana 告警并查询 Loki 日志上下文，结合**RocketMQ 异步削峰、Redis 指纹去重与规则化日志降噪压缩**能力，保障系统在告警风暴下稳定运行。采用**RAG 向量检索优先策略**，依托 Milvus 检索历史故障案例，命中则直接返回分析结果，未命中再调用大模型推理，有效降低 AI 调用频次、提升响应速度与故障分析准确率
- 基于**Plan-Execute-Replan** 架构实现运维Agent，实现权限分级执行模型，DANGEROUS操作强制人工审批，实现了**感知告警信息 → 推理 → 调用工具 → 分析结果 → 生成方案**的完整业务流程