

王哲

意向岗位：AI应用开发/后端开发

13247082346 | 13247082346@163.com



教育背景

中国地质大学（武汉）	211	硕士	电子信息(计算机)	2025.09-2028.07
江西师范大学		本科	软件工程	2021.09-2025.07

项目经历

校园心理关怀平台 Python 2026.04-2026.08

项目描述：面向高校心理陪伴与风险干预场景，开发学生端 AI 对话助手和后台风险处置系统。系统能够识别咨询、情绪疏导和高风险求助等不同意图，结合心理知识库生成回复，并对高风险对话自动生成报告和处置记录。

- Agent 编排：针对心理对话中意图识别、风险评估、上下文检索和回复生成分散在不同链路，导致单轮对话难统一编排和追踪的问题，设计 Agent Runtime Harness，并基于 CollaborationBlackboard、任务 claim 和 artifact 机制拆分 Understanding、Safety、Context、Response 等 Agent，统一管理单轮对话主链路。
- 检索优化：针对心理知识库单一路径检索导致召回不稳定、相关片段排序靠后的问题，先基于问题类型进行领域 query 扩展，再融合 Chroma 向量检索与 BM25 关键词检索召回候选结果，最后知识源匹配和答案相关性提升重排序稳定性；基于60条样本评测验证效果，Recall@4 达到 96.67%，MRR 达到 0.9417。
- 模型路由：针对不同复杂度和风险等级的请求统一调用大模型，导致成本增加、时延波动的问题，设计基于任务类型与风险等级的分层路由策略；在50次请求测试中，将 P95 响应时间由 29.2 秒降至 18.3 秒，降低 37.2%，单次调用成本降低 32%。
- 安全闭环：针对高风险识别、报告落库和后台处置分散在不同模块，导致风险流程难追踪的问题，将输入脱敏、风险评估、报告落库、工具计划和 run trace 收口到 Harness，支持心理风险报告、工具计划和 Agent 运行轨迹自动生成。

AutoSite Java 2025.12-2026.03

项目描述：面向自然语言建站与网站快速搭建场景，开发 AI 零代码 Web 应用生成平台。系统能够根据用户的一句话需求生成网站，并支持多轮修改、历史版本查看和一键回滚，解决 AI 生成网站难维护、修改后难恢复的问题。

- 性能优化：针对每次生成都重复创建工程骨架，导致生成耗时和 Token 消耗偏高的问题，构建模板匹配与占位符替换链路，复用后端完整模板、局部替换和构建校验能力；首 Token 时间约 4510ms，生成时间从42秒降至22秒，生成耗时降低约 47.61%，Token 消耗降低约 30%
- 版本管理：针对多轮生成只保留最新结果，导致历史版本难追溯、误操作后恢复成本高的问题，基于版本记录和内容 Hash 追踪代码文件变更，支持历史版本预览、差异恢复和一键回滚，平均回滚时间约 3179ms。
- 限流隔离：针对 AI 生成请求并发进入同一模型链路，导致请求堆积和会话上下文串扰的问题，基于 Redisson + AOP 实现用户级、接口级限流，并结合 Caffeine 缓存复用模型服务实例，提升生成接口在并发场景下的稳定性。

专业技能

- Agent 开发：熟悉 Agent 相关概念与基础架构设计，理解 Prompt 约束、上下文管理、工具调用、Skill、Memory 等核心机制，具备 Agent 应用架构设计意识
- RAG 系统：了解 RAG 从查询优化、召回到后处理的优化流程，熟悉查询重写、问题拆分、混合检索、召回融合和重排序等方法，能够基于离线评测进行检索策略调优
- 数据库与缓存：熟悉 MySQL 索引、事务、锁、MVCC 和 SQL 优化；了解 Redis 缓存策略、分布式锁与缓存一致性处理，熟悉缓存穿透、击穿、雪崩的解决方案
- 后端开发：熟悉 Java/Python 开发，掌握接口设计、参数校验、异常处理和分层模块落地
- 工程实践：熟悉 Git、Docker、Apifox、JMeter，能够完成接口联调、项目构建、本地部署和压测分析
- AI辅助开发：利用 Codex、Claude Code 提升问题排查、方案设计，迭代开发和文档整理效率