

王嘉麟

13725472763 | 2381513477@qq.com | 深圳
应届生 | 深圳 | 大模型开发



教育经历

香港中文大学 (深圳) 海外QS前50

2025年09月 - 2027年06月

计算机信息工程 硕士 全日制

GPA: 3.1/4.3 相关课程: 深度学习, 数据分析, 信息论, 高级计算机网络

东南大学 985

2021年09月 - 2025年06月

人工智能 本科 吴健雄学院 全日制

GPA: 3.21/4.0 IELTS: 7.0 CET-6: 594 CET-4: 628

项目经历

JLClaw · 自托管多渠道开发助理 Agent 系统

2026年05月 - 2026年08月

项目介绍: 该项目是一个基于 Python + DeepAgents + LangGraph 构建的开源、可自托管的企业级 Dev 场景 Agent 系统,核心理念为 "Harness Engineering, Not Model Engineering" (Model + Harness + Eval = Reliable Agent)。系统以研发协作助手 DevMate 为运行案例,围绕 "Issue → 规划 → 在隔离沙箱中改代码 → 跑测试 → 安全自查 → 提交改动" 的完整研发链路,支持多渠道接入、多模型路由、长任务异步化与生产级资源隔离,具备完整的服务端业务逻辑与 API 实现。

核心技术栈: Python 3.13, DeepAgents 0.6 / LangGraph 1.x / LangChain, FastAPI, PostgreSQL, Redis, Docker, arq, FastMCP, Alibaba Qwen(qwen-max/plus/turbo), SSE, SlowAPI, LangSmith, Prometheus, locust, uv

核心功能: 多模型路由与 Harness Profile、子代理协作、自托管隔离沙箱(容器/gVisor/microVM 分级)、多渠道网关、长任务异步队列、长短期记忆持久化、并发治理与限流、全链路可观测

- 多渠道统一接入与会话治理: 针对飞书 / Web / CLI / Webhook 多入口接入需求,设计了渠道抽象层 + 统一网关——通过 (租户, 渠道, 会话) → 稳定 thread_id 的派生机制实现多轮会话归属与多租户硬隔离;基于飞书长连接(WebSocket)接入应用机器人,用 run_coroutine_threadsafe 解决 SDK 同步回调与异步事件循环的桥梁;网关层实现 API Key 鉴权与按租户的身份贯穿。
- 多模型路由与中间件解耦架构: 设计 Harness Profile 机制,通过中间件按场景(strong / standard / cheap 档位)动态路由 qwen 模型,实现"模型选择"与"业务逻辑"解耦;基于 awrap_model_call 等中间件钩子实现成本计量、工具审计、LLM 并发控制、模型 fallback(主模型限流/故障自动降级到备用模型),业务代码零侵入。
- 自托管隔离沙箱与执行安全: 针对"开源可自托管产品不应将不可信代码执行外包给境外 SaaS"的定位矛盾,自建隔离沙箱方案——梳理容器(runc 加固) / gVisor(runsc) / microVM(Kata-Firecracker) 三档隔离强度并按部署场景选型;实现统一 BaseSandbox 接口,基于 Docker 构建加固容器(断网 / 丢能力 / 只读根文件系统 / 资源上限 / 非 root / 用完即弃),并实现"换一行 runtime 配置即切换隔离级别、上层代码不变"的可插拔抽象;用 FilesystemPermission 与容器只读挂载实现审查子代理的物理只读(机制优于提示词约束)。
- 长任务异步化与任务队列选型: 针对飞书 3 秒响应限制与同步长任务阻塞问题,完成从 FastAPI BackgroundTasks(轻量、状态表持久化)到 arq + Redis 任务队列(独立 worker、可水平扩展、失败重试)的选型与实现;用 arq_job_id(飞书 event_id)实现幂等,替换内存去重为 Redis SET NX + TTL,保证跨副本、重启不丢的事件去重。
- 并发治理与服务弹性: 设计"有限资源 + 按租户隔离"的并发护栏——asyncio.Semaphore 在 LLM 调用层限并发(精确粒度,非包整个 agent)、沙箱池(隔离优先、用完即弃、上限回收)、SlowAPI 按租户限流(Redis backend 多副本共享、超额 429);并诚实标注信号量进程级、permissions 不覆盖沙箱 execute 等能力边界。

TravelMind — 多Agent协作

2026年01月 - 2026年04月

项目介绍: 该项目是一个基于 Python + LangGraph 构建的企业级智能旅行规划系统,采用多 Agent 协作架构设计。系统综合运用 Handoffs 流程编排、Router 智能路由、Subagents 工具调用三大架构模式,通过多轮对话引导用户完成从需求收集到生成完整旅行规划的全流程,具备完整的服务端业务逻辑与 API 实现

核心技术栈: Python 3.13, LangGraph/LangChain, LangSmith, FastAPI, PostgreSQL, Redis, ChromaDB, FastMCP, Alibaba Qwen, SSE

核心功能: 多 Agent 协作编排, Advanced RAG 深度检索, MCP 协议工具接入, 长短期记忆持久化, 流式输出, 状态回退, 全链路监控

- 多模式 Agent 架构: 针对复杂旅行规划场景,设计了 Handoffs+ Router+ Subagents 三种模式融合的架构,通过 Middleware 中间件根据 current_step 动态注入步骤级提示词与工具集,实现业务逻辑与框架代码的解耦。
- RAG 引擎构建: 针对非结构化旅游攻略文档的精准检索需求,构建了四阶段优化管道: 查询优化、混合检索、LLM 重排序(结构化评分过滤噪声)、父文档上下文映射,并基于 Redis 实现检索结果缓存加速。
- MCP 协议标准化工具接入: 基于 FastMCP 框架搭建自建 MCP Server, 将外部 API 能力封装为标准化工具服务。客户端侧基于 MultiServerMCPClient 实现统一的多服务连接管理,兼容 stdio 与 Streamable HTTP 两种传输方式。
- 长短期记忆双轨持久化: 基于 PostgreSQL 实现 Checkpointer+ Store。通过 Middleware 中间件在每次 LLM 调用前自动加载用户长期记忆注入提示词,实现个性化推荐
- 工程化设计与实时交互: 采用单例模式 + 工厂函数管理核心组件的生命周期;基于 FastAPI + SSE 实现实时 Token 流式推送通过 Pydantic Settings 统一管理环境变量配置,集成 Loguru 增强日志与 LangSmith 调试监控

荣誉奖项

Kaggle: NeurIPS - Ariel Data Challenge 2024 (Competition Silver Medalist)

2024.08-2024.11

专业技能

- 大模型微调推理: Transformer、PyTorch、LoRA/QLoRA、LLaMA-Factory、vLLM 量化加速
- Agent 开发: Langchain&LangGraph、DeepAgent; 自研 Agent Harness、标准化 Agent Loop、MCP/FastMCP Skill 工具、多智能体协同
- RAG 系统: 混合检索、Rerank、GraphRAG、Agentic RAG、Milvus/Chroma、RAGAS 评测
- 工程交付: FastAPI、MySQL/PG/Redis、Docker、Harness CI/CD、LangSmith、Locust 压测、Prometheus、Grafana