



邹骏恺

男 · 25 岁 · ☎ 18002270663 · ✉ 605838411@qq.com

🎓 教育经历

深圳大学	硕士 计算机技术	2024 – 2027
深圳技术大学	本科 物联网工程 CET-6	2019 – 2023

⚙️ 专业技能

- **编程基础**：熟悉 Python 及模块化开发、第三方库组织；熟悉 C++ 面向对象、STL、C++11 常用特性、数据结构与操作系统基础。
- **Agent**：熟悉任务规划、工具调用、上下文 / 记忆管理、Harness Engineering、Function Calling 与结构化输出；能基于 LangGraph 组织工作流，处理条件路由与失败修订。
- **RAG**：熟悉文档切分、Embedding、向量检索与生成评估等 RAG 基本链路；熟悉 Multi-Query、RAG-Fusion、rerank 与 RAGAS 评估等 RAG 优化方法。
- **Agent 工程化**：具备服务化、流程验证、可观测性与质量评估意识，熟悉 MCP / A2A，熟练使用 Codex 辅助需求拆解、代码生成与缺陷定位。

👤 项目经历

企业级采购 AI Agent 平台

2026.05 – 2026.07

独立开发 Python / FastAPI / PostgreSQL / Redis / Skyvern / Playwright / Pydantic v2 / React / TypeScript / Docker

<https://github.com/kublesd/procurerpa-enterprise>

项目目的：在 Skyvern 开源 AI-RPA 框架上补齐企业采购所需的权限隔离、风险审批与全程审计能力。

- 设计风险双阶段识别：规则词库预筛（预算、拆单、单一来源、敏感品类、异常低价等 100+ 策略），命中后由 LLM 结合页面上下文生成风险说明并路由审批，无效 LLM 调用减少约 70%。
- 实现 LLM 三层容错：Prompt 层强制结构化 JSON 输出、解析层 Pydantic v2 校验与指数退避重试、任务层失败转 NEEDS_HUMAN 并提供证据查看与人工接管流程。
- 设计 Planner + Executor 协作架构：Planner 用 LLM 将查询报价拆解为子任务序列，Executor 复用 Skyvern 原生 Task / Workflow / Action 链执行；replan 仅重规划剩余任务，状态持久化支持断点续跑。
- 封装 7 个可组合采购 Skill 与 6 个工作流模板（统一 Pydantic 接口），审计回调自动掩码密码、报价与合同字段。
- 基于网页 DOM 元素数量、iframe 嵌套、动态内容三特征评分，路由至三档模型；结合 Redis action 结果缓存（TTL 24h、DOM 结构 hash 为缓存 key），单任务 LLM 调用费用降低约 60%。
- 识别高风险采购操作后，结合任务所属组织、部门、品类与金额，动态路由审批请求给具备相应授权的 approver；LLM 只生成风险说明，审批层级与供应商推荐均由确定性规则决定。

DocuMind：企业级 RAG 知识问答平台

2026.02 – 2026.04

独立开发 Python / FastAPI / PostgreSQL / Qdrant / MinIO / React / TypeScript / RAGAS / pytest

<https://github.com/Kublesd/DocuMind>

项目目的：构建“文档入库—混合检索—证据生成—评测回流”的企业级 RAG 问答链路。

- 设计知识入库链路：PDF / Markdown / TXT / Word 上传 → 解析（表格结构化、图片 OCR 提取文本）→ 标题 / 页码父子分块 → Dense / Sparse 索引；子块负责精准召回、父块补全上下文，每个分块附带章节、来源版本、ACL、有效期、冲突状态等元数据，用于检索过滤与定向召回；对答案分散在多个片段的问题，证据命中率从 61.2% 提升至 82.6%（基线为固定长度切块）。
- 构建查询检索链路：为兼顾语义问题与专有名词匹配，实现追问补全与关键词扩展 → 语义向量、关键词、元数据过滤三路召回 → RRF 融合去重 → rerank，全程强制租户与权限隔离，用户只能检索有权限的文档；与纯向量检索基线对比，整体 Recall@5 从 78.2% 提升至 87.3%（精确术语组 93.2%），零额外 LLM 调用。
- 实现证据生成链路：为让答案可溯源，实现排序结果 → 按 Token 预算保留关键事实与父级上下文 → 结构化答案 → 引用校验；证据不足、引用越界或敏感输出时拒答并返回空引用；输入端拦截 6 类 Prompt Injection；4000 Token 预算内关键事实覆盖率 96.3%，10 条拒答用例（无依据、引用越界、敏感输出）全部拒答并返回空引用。
- 建立评测反馈闭环：全链路留痕，RAGAS 自动评测（ContextPrecision 0.913、ContextRecall 0.906、Faithfulness 0.952）后将失败案例与用户反馈加入固定回归集；自建 100 题企业基准集（五类企业数据源、276 条人工标注标准片段）上文档召回率 95.9%。

Competitive Analysis Agent：可验证竞品分析 Agent

2026.04 – 2026.05

独立开发 Python / LangGraph / LangChain / Pydantic / Tavily / Streamlit / FastAPI / pytest

https://github.com/kublesd/competitive_analysis_agent

项目目的：将分散的公开产品资料整理为附带来源、可验证的竞品分析报告，降低人工调研成本。

- 用 LangGraph 串联规划、搜索、抽取、对比、引用检查与报告生成；检查未通过时仅修订分析步骤 1 次，避免反复重试。
- 用 Pydantic 统一任务、资料、产品画像与结论结构；按产品、主题、URL 去重 Tavily 结果，并标记可用 / 排除 / 待确认。
- 校验引用存在性、产品归属与价格冲突，再由模型判断资料能否支撑结论；失败时基于已有资料降级生成简化报告，避免整份失败。
- 提供 Streamlit / FastAPI 入口与阶段日志；3 个预设场景自动测试全部通过，产品范围与引用编号校验通过。