



姓名：郭 轩
年龄：23

电话：15671376639
邮箱：1643007089@qq.com



教育背景

2024.09~2027.06
2019.09~2023.06

深圳大学
武汉东湖学院

硕士
本科

计算机技术
软件工程

在校荣誉：硕士二等奖学金、第八届“数竞杯”数据智能创新应用大赛国三、中国大学生计算机设计大赛省一、CET6

专业技能

- 计算机基础与算法**：精通 Python，熟悉Java，掌握计算机网络、操作系统核心知识；了解 Transformer 模型架构、注意力机制底层逻辑；熟悉 Linux 常用命令、Git 版本控制。
- 大模型与应用**：了解大模型应用开发流程，掌握 Agent 与 RAG 检索增强生成的深度融合，熟悉文档分块、多路召回、重排优化流程；掌握 Milvus 向量数据库的索引设计、检索性能优化。
- Agent 开发**：掌握 ReAct、Reflexion、CoT 等主流智能体推理框架；掌握 Multi-Agent 多智能体协作机制，角色分工、任务拆解、冲突解决的核心方案；熟悉 Langgraph、Agno 等开源框架的架构与二次开发。
- 前后端技能**：熟悉 FastAPI、Spring Boot 后端开发框架；掌握 MySQL 数据库及 Redis 缓存技术；熟悉 Vue3 开发框架。
- 熟练使用**：Cursor、Codex 等 AI 编程工具，能够检查、调试和改进 AI 生成的代码。

实习经历

深圳市云中鹤科技股份有限公司

AI 开发实习生

2026.02~2026.06

云鹤智标—ToB 招投标书AI生成系统

- 背景与目标**：针对企业招标文档处理效率低下、核心条款提取偏差大等痛点，负责构建高效的自动化解析与生成系统。
- 技术方案**：设计了本地双引擎路由解析架构，集成 MinerU 处理扫描件，统一将 PDF/DOC/DOCX 等异构文档标准化 Markdown 格式；针对百万字级复杂标书，采用 **Multi-Agent** 协作与 **Map-Reduce** 并行抽取策略。
- 行动与优化**：构建三层冲突消解机制，精准提取 **5000+** 条核心商品条款；通过复用 Prompt Cache 技术，重构消息分层架构，将稳定上下文与动态任务分离，使同父节点下的多叶子节点共享缓存前缀；通过预编排-并发-审计三段式架构，优化长文本生成链路。
- 结果**：实现全自动文档解析，相比串行处理速度提升 **86.5%**，并通过预编排-并发-审计三段式架构，确保了多模态内容上下文一致性与 Mermaid 图表的稳定渲染；缓存命中率高达 **98.5%**，将 10w 字标书生成成本降低至 1 元以内。

网易七鱼工单回复助手 (Chrome Extension + FastAPI + Agno + Milvus + ElasticSearch)

- 背景与目标**：为售后业务团队开发智能化回复助手，实现从0到1的需求分析，开发至测试部署。
- 技术方案与执行**：设计了基于 **FastAPI** 的后端链路，集成 **Milvus** 向量库与 **ElasticSearch** 全文检索，采用 **Agno** 框架编排智能体 workflow，支撑业务团队项目问答，建议以及总结等场景。
- 工程化优化**：针对 Agent 检索死循环问题，实施 **tool_call_limit** 硬限制及超时熔断策略 (60s)；针对 SaaS 系统 DOM 频繁变更，设计“固定字段ID -> label语义匹配 -> 结构解析 -> 正则提取”的 4 级兜底获取策略，确保数据采集零缺失，支撑日均 1000+ 工单处理，端到端响应优化至 3s 内。

人工智能与数字经济广东省实验室（深圳）

大模型实习生

2025.06~2025.09

基于强化学习 (RL) 的长链路 Agent 规划与工具调用优化

Task: 针对长链路任务指令跟随弱、Tool Calling 准确率低痛点，0-1搭建 VeRL Post-training 流水线，利用 RL 提升严苛约束下执行能力。

- 数据工程与采样策略**: 构建包含通用推理、代码生成及工具调用的多任务混合数据集(9k+)。设计基于熵的动态采样(Dynamic Sampling)策略，在训练中动态平衡通用认知与特定工具执行能力的权重，有效防止灾难性遗忘。
 - 算法选型调优**: 对比 GRPO/DAPO/GSPO 等策略，针对巨大动作空间设计“Cold Start + RL”两阶段范式，稳定大规模模型收敛。利用 Ray + FSDP 稳定训练。
 - 分层奖励塑形**: 针对长链路任务中反馈稀疏的痛点，设计基于 Smart Router 的分层奖励系统。构建并行的评估链路：在逻辑层引入数学/代码正确性校验，在执行层设计细粒度的工具校验链（格式检查 -> JSON 校验 -> API 名称核对 -> 参数验证），从规划逻辑、参数格式、执行结果三个维度对模型进行密集反馈 (Dense Reward)，引导模型学习严谨的动作约束。
- Result**: 复杂任务的端到端成功率由 4% 提升至 33% (8.25x)，工具选择准确率提升至 87%，参数填充正确率从 0 突破至 33%，结合 vLLM 推理引擎与熵动态采样策略，将样本生成效率提升 33% (600step -> 400step)，相关方案已在实际环境中完成部署与验证。

项目经历

InsightForge — AI 短剧生成 Agent

主要开发者

2026.05~2026.07

地址：<https://github.com/gx-ui/Insightforge>

技术栈：Python + FastAPI + LangGraph + React + FAISS + Redis + MySQL

项目介绍：将“一句话创意/小说 -> 完整成片”的创作链路抽象为角色化、可协作的多智能体协作系统，完整覆盖叙事规划、跨镜头视觉一致性保障、图像与视频生成执行、成片组装与质量校验，实现从文本创意到高质量多镜头长视频的自动化创作。

- 设计并实现基于 Event Streaming 的 Agent 循环**：单轮对话内支持最多 50 次工具调用，通过 token / tool_start / tool_progress / tool_result / terminal 等结构化事件，将模型推理、工具执行与终端输出统一为可观测的事件流，用户可实时看到执行状态。
- 构建 13 个专业化智能体**（剧本生成、分镜设计、镜头规划、角色提取等），通过 Idea2Video/Script2Video/Novel2Video 三条端到端流水线串联，将“创意 -> 剧本 -> 分镜 -> 镜头 -> 关键帧 -> 视频片段 -> 成片”全链路自动化。
- 实现工具调用并发分区机制**：在工具注册时声明并发安全标记，运行时对安全工具自动合并到同一批次并行执行、串行依赖的工具单独成批；在保证执行正确性的前提下，将多镜头渲染的串行等待压缩为并行流水，缩短长视频整体生成耗时约 **45%**。
- 针对长篇小说改编场景 (Novel2Video)**：设计“叙事压缩 + 事件抽取 + 场景切分 + 全局信息规划”的组合策略，以全局角色档案与场景约束驱动后续分镜，解决长文本改编中常见的角色外观漂移与场景割裂问题。
- 集成 FAISS 向量检索 + BGE 重排序的参考图召回链路**：分镜生成时按角色与场景语义检索历史参考图，结合首帧与机位连续性约束传递至视频生成器，保障跨镜头的视觉一致性。