

马誉轩

电话：18936888211 | 邮箱：18936888211@163.com | 出生年月：2004 年 6 月

教育背景

2026.09-2028.02 (预计)	香港城市大学 (QS51)	计算机科学 硕士
2022.09-2026.06	南京师范大学 (211、双一流)	计算机科学与技术 本科
● 主修课程：数据结构(84)、操作系统(82)、计算机网络(93)、离散数学 (95) 、编译原理(90)、计算机组成原理(82)等。		

实习经历

2026.05-2026.7	江苏鲲鹏昇腾生态创新中心	现场技术支持实习生
● 参与 DeepSeek-V4 模型在昇腾集群上的部署与压力测试，基于 vLLM 框架进行参数调优，收集并分析延迟、吞吐、并发等核心性能指标。		
● 针对 DeepSeek-V4 的 DSA 稀释注意力等特性，调整推理参数配置；实操投机解码与预测模块的启用流程，观察对解码效率的影响；配合完成 MoE 架构下的通信优化参数设置及 CANN 编译器相关内存优化选项的配置，验证官方提供的调优策略在真实负载下的效果。		
● 参与昇腾内部算子调优 Agent 的 Skill 设计工作。基于对算子调优流程的理解，协助设计针对特定算子的 Skill 逻辑，包括定义性能诊断步骤、工具调用接口及优化方案生成规则，深入理解了 Agent 中 Skill 的模块化设计、规划-执行-反馈机制。		

项目/校园经历

2026.04-2026.06	Reactor-agent 多智能体协同平台
项目围绕复杂任务拆解、多 Agent 协同执行、工具编排、RAG 检索增强、会话记忆、执行账本与 SSE 流式交互等能力，构建了一套可追踪、可复用、可扩展的 Agent 工程化落地框架，支持深度搜索、数据分析、报告生成、图像生成、多模态知识库问答等场景。	
● 技术栈：JAVA, Spring boot, Spring AI, MyBatis, MySQL, Qdrant, RAG, MCP, React	
● 构建多 Agent 协同调度机制，通过统一调度层按任务类型动态选择 ReAct、PlanSolve、Workflow 等执行策略，并支持子智能体远程挂载，实现主 Agent 与搜索、报告、代码解释器、图像生成等能力的协作。	
● 设计并实现 SOP 语义召回机制，在任务规划阶段基于历史相似任务检索可复用执行流程，为 Plan-Execute 规划提供步骤参考，降低复杂任务中的模型跑偏、步骤遗漏和交付不一致问题，提升多步骤任务执行稳定性与完成度。	
● 基于 Qdrant 构建多模态混合检索体系，融合语义向量召回、BM25 关键词召回、文本到图片/页面跨模态召回，并结合查询重写、子问题扩展、多轮检索与 Rerank 机制，提升图文混合知识问答场景下的证据召回质量与结果相关性。	
2026.06-2026.08	自进化命令行 coding Harness Agent
集成自主会话记忆折叠、Skills 自进化、MCP 与子 Agent 的自进化 Harness Agent	
● 技术栈：Python、OpenAI SDK、Anthropic SDK、MCP、JSON-RPC、Docker、Skills	
● 自研 Python Agentic Harness，统一编排模型推理、工具调用、权限控制、会话恢复、自主会话记忆折叠、Skills、MCP 和子 Agent。	
● 构建 Skills 自进化质量评测机制，基于来源追踪构造 replay 样本池，结合规则评测、LLM judge、候选版本试跑和优胜版本登记，保证能力沉淀可回放、可比较、可审计。	
● 实现 Memory + Skills 分层长期上下文，Memory 保存项目事实和用户偏好，Skills 保存可复用任务流程，并支持 BM25-lite 检索、inline / fork 执行和长期记忆召回。	

技能/优势

- 后端开发：熟悉 Java（精通集合框架、多线程、IO 流、JVM 基础调优），Python，熟练使用 Spring Boot，MyBatis 框架
- 数据库：熟练使用 MySQL，掌握事务管理、SQL 优化、索引设计，了解分表分库基本思路。
- Agent 开发：理解 Agent 基本架构（规划、状态管理、工具调用），熟悉 Agent 相关架构，了解 RAG 以及 MCP 协议
- 英语能力：CET6（518），雅思（6.5）