

黄浩翔

求职意向：AI工程师

19925461499 | 19925461499@163.com



教育背景

2023-09 - 2027-06

华南师范大学 (211)

人工智能 (本科)

主修课程: 数据结构、操作系统、数据库基础、软件工程、python语言程序设计、神经网络、机器学习

职业技能

专业技能:

大语言模型与Agent: 熟悉大模型应用开发, 能够基于 **LangChain**、**LangGraph** 完成复杂 workflows 设计与 Agent 构建。深入理解 **MCP**、**Function Calling** 等工具调用机制, 了解A2A多智能体通信协议。深入了解**Diffy**功能架构且有开发、维护其竞品的经验。熟练运用 **Cursor**、**Claude Code** 等前沿 AI 编程工具辅助全栈开发。

提示词工程: 熟练掌握各类提示词策略 (**Few-shot**, **CoT**, **ReAct**), 有通过优化Prompt设计, 将复杂推理任务的准确率提升了15%-20%, 并有效降低模型幻觉的经验。

检索增强生成 (RAG): 具备完整的 RAG 系统落地经验, 掌握从**文档解析**、**切片**、**向量化召回**、**BM25 关键词检索**、**重排序**到生成约束的全链路技术, 熟悉 Milvus、Redis、MySQL 等组件在 RAG 场景下的集成与优化。

机器学习与深度学习: 掌握监督学习 (KNN、随机森林)、非监督学习 (KMeans) 及集成学习 (XGBoost、AdaBoost); 熟悉深度学习基础 (CNN、TextCNN、RNN、LSTM) 及Word2Vec词嵌入; 熟练使用预训练模型 (BERT、Qwen、LLaMA等) 及PyTorch、HuggingFace、Ollama等工具。

自然语言处理: 熟悉NLP核心任务 (文本分类、机器翻译), 深入理解**Transformer**与**Attention**机制。

模型优化与评估: 掌握模型调优策略 (优化器选择、学习率预热、正则化、超参数搜索) 及梯度裁剪; 了解模型压缩技术 (量化、剪枝、知识蒸馏); 熟练使用评估指标 (F1-score、混淆矩阵) 及分类报告。

编程与工程能力: 熟练使用Python、SQL, 掌握Pandas/NumPy进行数据清洗、特征工程与可视化; 熟悉Linux环境及常用命令; 具备MySQL数据库操作能力, 了解Milvus等存储引擎; 掌握Flask/Docker基础, 能够完成模型服务化部署。

实习经历

2026-04 - 2026-08

深圳飞速创软科技有限公司

AI Agent平台优化实习生

1. 开发和维护**AI工作流平台FlyGPT** (对标**Diffy**), 为**小天才** (知名儿童智能设备品牌) 提供基于低代码 AI 平台的 Agent 工作流与知识库检索能力, 支撑其内部运营问答、设备文档查询等场景。对Agent平台进行**系统性功能开发**和**核心功能优化**。独立负责**Agent 数据库工具**、**多轮对话记忆管理**、**知识库检索链路**等核心模块的优化。

2. 为**中国电信**、**博彦银行**等知名品牌提供基于**opencode框架+知识图谱引擎**的数据治理服务, 基于本体建模和多用户管理系统, 为甲方提供数据建模与管理, 支持其内部数据查询、业务分类、审核等场景。独立完成了业务核心建模、数据管理模型的建立, 打通业务流程, 并跨部门**主导**完成了应用的上线与部署。

项目经历

2026-04 - 2026-06

小天才Agent平台系统优化

项目介绍: 深度参与**小天才**内部运营问答与设备文档查询场景, 为低代码 AI 工作流平台 (对标**Diffy**) 设计并落地 Agent 核心链路的系统性增强方案。独立负责 **数据库工具输入压缩** (压缩率 87%)、**多轮记忆污染根治**、**知识检索耗时降低 75%**, 形成从问题发现、方案设计到客户交付的**完整闭环**。

技术栈: **opencode能力集成**, Python (FastAPI)、LangChain、MySQL、向量数据库、Rerank 模型、Vue.js、Docker、Git、广度优先搜索

项目内容:

1. Agent 数据库工具 (Database Tool) 输入超限优化:

针对数据库表结构过大 (500+表、99 万字符) 导致模型上下文超限的问题, 独立设计**表名智能筛选算法** (精确/部分匹配用户指令), 实现按 token 预算的**原子截断** (以 **CREATE TABLE** 边界拆分, 从后向前移除表块), 并增加**字符数双重校验**。

2. 多轮对话记忆污染修复:

解决 iframe/调试模式下**上下文串扰** (上一轮检索结果污染下一轮回答), 对比企微 API 正常调用, 定位根因为前端会话 ID 未

重置及历史消息未清空, 强制每次对话生成唯一 **conversation_id** 并清空本地缓存。

3.知识库检索链路性能与准确性优化：

处理检索耗时从 2-3 秒飙升至 20 秒、闲聊误触发、业务文档与测试小说混杂等问题，独立实施意图前置过滤、检索结果数量硬限制、相似度阈值过滤、文档类型标签隔离等优化。

4.Agent 重排分数融合优化：

修正混合检索误用重排原始分数（0.24）代替融合分数（0.6）阈值过滤 bug，设计新融合公式，提升召回率与排序准确性。

5.为 workflows 加入自主推理能力：

对平台的工作流节点、MCP 工具等进行注册，随后把本地 **opencode** 推理能力接入 Agent 工作流平台，让 Agent 接收用户需求描述，随后进行 **意图识别、提示词优化、自主搭建、测试工作流** 并完成任务；最总将远端 flywork（结合 claude code，opencode 等强力 Agent 框架打造的自研平台）接入工作流平台，保证稳定的工作流自主推理能力。

项目成果：

- 1.数据库工具输入从 **99 万字符** 压缩至 **12 万字符**，压缩率达到 **87%**，模型超限错误消除，工具调用成功率 100%。
- 2.上下文污染彻底解决，记忆隔离稳定。
- 3.平均耗时从 20 秒降至 5 秒（**降幅 75%**），“答非所问”用户 **反馈归零**。
- 4.重排召回率提升 **20%**，用户搜索体验改善。
- 5.**独立完成**所有问题的 **全流程**（定位、设计、实现、验证、上线、客户对接），方案沉淀为团队 Agent 上下文管理通用模板。

2026-06 - 2026-08

中国电信工单智策系统

项目介绍：作为 AI 应用架构设计者，基于 **LLM+OWL 本体+Neo4j 知识图谱+SWRL 规则引擎** 构建 Agent 协作系统，实现流量超量费投诉的分钟级自动判责与诊断报告生成，将工单处理时间从数小时缩短至八分钟内，且支持任务并行处理与多用户管理。

技术栈：gitlab，CI/CD，**opencode 框架整合**，Flask 后端框架，Neo4j 图数据库，Vue3 前端，Docker 容器化部署，OWL/RDF 本体建模

项目内容：

- 1.两阶段审查架构设计，确立一阶段进行 **文档规范性审查**、二阶段进行 **条款内容合规审查** 的核心分层原则，开发端到端审查全流程（文档上传→自动解析→图匹配→冲突检测→报告生成），实现从上传到报告的 **完整合规审查链路**。
- 2.开发 10 项文档规范性审查规则覆盖 4 大类（格式规范、结构完整、要素完备、逻辑一致），设计条款级冲突检测 5 类规则（直接冲突/缺失条款/模糊条款/过时条款/逻辑矛盾），结合 **Cypher 图查询** 实现规则执行，确保审查结论都能 **追溯到具体的文档/条款数据**。
- 3.构建审查服务层实现 **文档解析、图匹配、规范性检查、报告生成** 4 大核心模块，集成 FastAPI 与 **Neo4j 知识图谱**，定义 8 种关系类型，实现从上传文档到审查报告的全自动化。
- 4.在 gitlab 上完成了从仓库搭建、代码推送与分支管理，到 **CI/CD 构建、docker 容器化部署** 的流水线，并跨部门合作部署 K8s 集群，完整主导让项目从创建到部署客户端全流程。

项目成果：

构建 10 个 OWL 本体实体类、共计 **2764+ 节点** 的 Neo4j 知识图谱，定义 15 种语义关系类型，为规则推理提供统一语义基础，允许应用在接入强力 Agent 框架的情况下以不到十分钟的时长进行深度精准审核，并且通过 **提示词工程、skill 设计** 让 AI 输出查询的 **真实数据、推理具体过程**，减少幻觉并增强输出稳定性。架构复用至 **华为数据管理、博彦银行合同合规审核** 等多场景扩展。

2025-09 - 2025-11

多 Agent 智能就医助手系统

项目背景：针对传统就医流程繁琐、信息分散的问题，设计并实现了一个多 Agent 协作的智能就医助手。系统基于 MCP 统一封装服务接口，通过 A2A 协议实现 Agent 间协同，并引入 **思维队列架构**，支持复杂就医任务的多步推理与自主执行。

技术栈：FastAPI、LangChain、OpenAI、MCP / A2A 多 Agent 架构、**ReAct + ThoughtQueue**、Text-to-SQL (MySQL)

项目内容：

- 1.**实现 Agent 核心执行器：**设计 SimpleAgent 主控类，维护对话历史、工具注册表和 LLM 客户端，实现 **外层（步骤级）+ 内层（推理级）** 双循环架构；开发 **ThoughtQueue** 思维队列，支持任务步骤的动态追加（append）、插入（prepend）和替换（replace），并设置最大循环次数防止死循环。
- 2.**基于 MCP 协议集成外部工具：**使用 MCP Server 封装医院挂号查询、医保政策检索、费用计算等工具，通过 MCP Client 实现 Agent 与工具的标准交互。在医保 Agent 中集成 **Text-to-SQL** 能力（LangChain + ChatOpenAI），用户可直接提问“在职职工去三甲医院看门诊能报销多少”，Agent 动态生成 SQL 并查询医保规则数据库。
- 3.**构建多 Agent 协作机制（A2A）**
设计主控 Agent 与领域 Agent（挂号、医保、科室推荐）的通信协议，主控 Agent 负责 **意图解析** 与任务分解，领域 Agent 专注执行。基于 A2A 协议实现 Agent 间的请求/响应与结果聚合，支持超时重试和错误回退。
- 4.**完善前端与部署**
使用 Streamlit 构建聊天界面，实时展示 Agent 的思考步骤与工具调用链。基于 FastAPI + Uvicorn 部署 Agent 服务端，提供

HTTP 与 WebSocket 接口，支持流式输出。

项目成果：完成了一个可自主执行多步骤任务的就医助手，能处理任务复杂链路。通过 ThoughtQueue 实现动态重规划，支持在用户中途改变需求，系统能自动插入新步骤并调整后续计划。**意图准确率达到93%，端到端成功率达到91%。**

2024-10 - 2024-12

文本分类项目

项目背景：电商平台海量用户评论需实时识别情感倾向与细粒度方面（物流、质量、服务），人工分类效率低成本高，需构建自动分类系统实现高效评论洞察。

技术栈：Python, PyTorch, Scikit-learn, FastText, Transformers (Bert), 模型量化, 知识蒸馏, Docker, Flask

项目内容：

1.数据预处理：清洗海量用户点击日志与资讯标题，完成分词、去停用词、文本截断等操作；针对类别不平衡问题，采用重采样与数据增强策略，提升小样本类别表现。

2.模型选型与迭代优化：

- (1) 首先使用随机森林（RF）构建**基线模型**跑通流程，发现其对语义理解有限；
- (2) 引入FastText，利用层次Softmax与N-gram特征，在保证推理速度的同时将准确率提升至91%；
- (3) 采用Bert微调，准确率达到94%，但模型体积大、延迟高；
- (4) 通过知识蒸馏，以Bert为教师、FastText为学生，将知识迁移至轻量模型，蒸馏后准确率回升至93%，兼顾精度与效率。

3.模型压缩：对Bert进行INT8量化，减少显存占用；通过知识蒸馏得到轻量学生模型，压缩模型体积，提升推理速度。

4.模型部署：封装模型推理接口，基于Flask搭建RESTful API服务；使用Docker容器化部署，实现环境隔离与快速扩缩容，保障服务稳定性。

项目成果：构建了一套覆盖从数据清洗、模型选型到压缩部署的全链路文本分类系统。最终线上模型在保持超出标准线的**准确率**的同时，极大提升推理速度。

2025-07 - 2025-09

RAG智能咨询系统构建

项目背景：公司咨询业务中，高频问题占比高、人工响应慢，且因数据私有无法直接使用公有大模型，需基于私有知识库构建RAG系统实现准确、低延迟的自动答疑。针对复杂问题、结构化文档等难点，设计了**多阶段优化策略**。

技术栈：混合检索与重排序、LangChain、Qwen2.5-7B-Instruct（通义千问）、MySQL（问答缓存）、Redis（热点缓存）、Milvus（向量数据库）、BM25

项目内容：

1.设计两级检索架构：第一级基于 **MySQL+Redis** 的问答缓存，通过 **相似度匹配** 直接返回高频问题的预存答案，避免大模型调用，降低延迟；未命中时触发RAG流程，进入第二级检索，使用LangChain整合Qwen2.5-7B-Instruct大模型，从本地文档库中检索增强生成。

2.开发文档处理流水线：支持PDF/Word/Markdown等多格式文档的加载、清洗、智能切分，并利用Sentence-Transformers生成向量，存入Milvus向量数据库。

3.多阶段查询优化与混合检索：引入查询优化机制，对复杂、多意图问题，通过**子查询拆分**、**假设文档嵌入（HyDE）**、**回溯提示**等策略，提升查询表达的精确度；采用**向量检索 + BM25 稀疏检索 + Rerank 重排序**的三阶段召回策略，提升召回准确率。

4.封装FastAPI服务：提供RESTful API与WebSocket流式输出，集成日志监控与Locust压力测试，确保系统稳定性。

项目成果：高频问题响应速度提升，降低了平均响应时间降。提高了问答准确率，有效减少模型幻觉、人工客服咨询量。**答案相关性达到94%。**

科研经历

2025-09 - 2026-06

面向开放世界的多模态意图认知建模与持续学习研究

算法实现负责人

研究背景：基于智能客服等场景下音频意图识别模型存在无法适应未知意图且难以持续学习的状况，通过构建音频理解系统，要达到为跨行业语音交互提供实时、低成本智能化支持的目标。

研究内容：

数据预处理：采集多行业客服电话音频，**搭建自动 workflow**，建造Agent节点、集成音频识别功能进行批量音频转写；采用利用Whisper提取声学与文本特征的方式，进行数据的清洗与标准化。

特征与建模：设计多模态语义表征，将意图抽象为可解释“概念”的方式，进行计算特征与概念一致性实现已知/未知意图判别；

持续学习框架：通过引入概念记忆回放与概念图谱扩散，结合Learngene范式（集体模型+LoRA轻量化适配）的方式，进行新知识学习与旧知识防遗忘。

评估验证：通过在自建多行业测试集上，划分已知/未知任务双轨评测，对比传统基线方法的方式，进行效果验证。

研究成果：获得**国家级立项、专项培育大创立项**，成功输出完整技术方案、核心算法代码库，验证了方法的创新性与落地潜力